



HE2: Consultoría Económica e IAR

Clase 4 - Ciclo de Vida de Datos

Catalina Bernal
Santiago Neira


Enero 29 2026
Semana 2

Contenido




Recordemos el ciclo	3
Estadísticos e Indicadores	4
Sesgos en los Datos	15
Otros riesgos	23
Un checklist	24

Ciclo de vida de los datos (Data Cycle)



Ciclo de vida - KNime

¿Por qué el promedio puede mentir?



✗ Crudo

Adult Income:

- Edad: 38.6 años
- Horas: 40.4/sem
- >50K: 24%

✓ Analizado

>50K por género:

- Hombres: 31%
- Mujeres: 11%

Por educación:

- Sin bach.: 5%
- Maestría: 62%

¿Por qué el promedio puede mentir?



✗ Crudo

Adult Income:

- Edad: 38.6 años
- Horas: 40.4/sem
- >50K: 24%

✓ Analizado

>50K por género:

- Hombres: 31%
- Mujeres: 11%

Por educación:

- Sin bach.: 5%
- Maestría: 62%

El promedio esconde **desigualdades**

Construcción de Indicadores



Ratios

Relación entre variables.
Por ejemplo:
ingresos/horas

Agregaciones

Resumir grupos. Por
ejemplo: promedio por
nivel de educación

Categorización

Crear grupos. Por
ejemplo: tiempo parcial,
tiempo completo



Construcción de Indicadores



horas/ingresos

- Valores altos = muchas horas por poco dinero
- ¿qué ocupaciones son más “eficientes”?

promedio por nivel de educación

- Sensible a outliers

Categorización

¿Por qué esto es útil?



Construcción de Indicadores



horas/ingresos

- Valores altos = muchas horas por poco dinero
- ¿qué ocupaciones son más “eficientes”?

promedio por nivel de educación

- Sensible a outliers

Categorización

¿Por qué esto es útil?

Diseñen 2 indicadores que revelen **desigualdad**



Construcción de Indicadores



horas/ingresos

- Valores altos = muchas horas por poco dinero
- ¿qué ocupaciones son más “eficientes”?

promedio por nivel de educación

- Sensible a outliers

Categorización

¿Por qué esto es útil?

- Calculables
- Interpretables
- Accionables



La Paradoja de Simpson



“Las mujeres, en promedio, ganan más que los hombres”

x Total

Promedio:

- Mujeres: \$42K
- Hombres: \$41.5K

✓ Por ocupación

Tech: M: \$55K (10%) — H: \$56K (40%)

Service: M: \$38K (90%) — H: \$37K (60%)

En CADA ocupación, los hombres ganan más. El promedio general es engañoso ¿por qué?

Cuándo usar media vs mediana vs moda



ESCENARIO: Ingresos de 10 personas

Datos: [30K, 32K, 35K, 35K, 38K, 40K, 42K, 45K, 48K, 500K]

Media	Mediana	Moda
\$84.5K ! Distorsionada	\$39K ✓ Típico	\$35K Más común

Cuándo usar media vs mediana vs moda




Métrica	Cuándo usarla	Cuándo NO usarla
Media	Distribuciones simétricas, sin outliers	Datos con valores extremos, distribuciones asimétricas
Mediana	Distribuciones asimétricas, con outliers	Cuando necesitas sensibilidad a todos los valores
Moda	Variables categóricas, identificar patrones	Distribuciones continuas sin picos claros

Cuándo usar media vs mediana vs moda



Métrica	Cuándo usarla	Cuándo NO usarla
Media	Distribuciones simétricas, sin outliers	Datos con valores extremos, distribuciones asimétricas
Mediana	Distribuciones asimétricas, con outliers	Cuando necesitas sensibilidad a todos los valores
Moda	Variables categóricas, identificar patrones	Distribuciones continuas sin picos claros





Un caso...

Quieren calcular "el salario promedio de personas con educación universitaria" en el dataset.

Opción A: Filtrar `education=='Bachelors'` y sacar `mean(income)`

Opción B: Hacer `groupby` por `[education, sex, race]` y luego promediar los promedios

Opción C: Hacer `groupby` por `[education, occupation]` primero, luego agregar

1. ¿Cuál opción elegirían y por qué?
2. ¿Qué sesgos podría introducir cada método?
3. ¿Para qué pregunta de investigación sirve cada una?



Sesgos en los Datos


Un sesgo es una desviación sistemática de la realidad que queremos medir, causada por cómo recolectamos, procesamos o interpretamos los datos. No es ruido aleatorio, es error direccional.

¿Por qué importa?

- Los algoritmos amplifican sesgos en datos
- Perpetúan desigualdades históricas
- Causan daño real a personas y comunidades
- Generan riesgo legal y reputacional para empresas



Sesgos de Selección



La muestra no representa adecuadamente a la población objetivo

Manifestaciones comunes:

- Survivorship bias (solo vemos los que “sobrevivieron”)
- Sampling bias (método de muestreo defectuoso)
- Non-response bias (quienes no responden son diferentes)

Ejemplo

Caso: Encuesta de satisfacción online

- Solo responden usuarios con acceso a internet
- Usuarios muy insatisfechos (cancelaron) no están en la base
- Usuarios muy satisfechos tienen más motivación para responder

Resultado: Sobreestimamos satisfacción.

Sesgos de Medición



Errores sistemáticos en cómo se capturan los datos

- Encuestas con preguntas sesgadas
- Proxies incorrectos
- Instrumentos de medición descalibrados

Ejemplo

Caso: Predicción de riesgo criminal (COMPAS)

- Variable objetivo: “arrestos futuros”
- Problema: Arrestos reflejan *actividad policial*, no necesariamente criminalidad
- Comunidades sobre-vigiladas tienen más arrestos
- El modelo “aprende” que ser de cierta raza = más riesgo

Resultado: Profecía autocumplida.

Sesgos Históricos



Los datos reflejan desigualdades del pasado

Ejemplo

Caso Amazon Recruiting (recordar intro)

- Datos históricos: 10 años de contrataciones
- Realidad histórica: Industria tech dominada por hombres
- Modelo aprende: “Hombre” = característica positiva

Ejemplo

Caso: Préstamos bancarios

- Históricamente, mujeres tenían menos acceso a crédito
- Datos muestran que mujeres tienen menos historial crediticio
- Modelo penaliza a mujeres por falta de historial
- Perpetúa exclusión financiera



Cómo las decisiones de limpieza introducen sesgos

Limpieza de datos es necesaria, pero cada decisión puede introducir sesgo.

Qué se hace usualmente:

1. Eliminar filas con datos faltantes
2. Imputar con media/mediana
3. Imputar con un modelo de ajuste / predictivo



¿Dónde está el sesgo?



Cómo las decisiones de limpieza introducen sesgos - NaNs

Ejemplo

Escenario: Dataset de solicitudes de empleo. 20 % no reportan salario anterior.

Si eliminamos esas filas:

- Perdemos desempleados de largo plazo
- Perdemos personas con trabajos informales
- Nuestro modelo asume “todos tienen historial formal”

Si imputamos con mediana:

- Asumimos que faltantes = promedio
- Invisibilizamos desigualdad salarial
- Reducimos artificialmente varianza





Cómo las decisiones de limpieza introducen sesgos - outliers

Ejemplo

Escenario: Modelo de scoring crediticio. Algunas personas tienen 15+ tarjetas de crédito (outliers).

Si eliminamos outliers:

- Removemos casos “anómalos”
- Pero: ¿Y si esos outliers son empresarios legítimos?
- El modelo aprende: “Comportamiento atípico = malo”
- Penalizamos innovación financiera



Punto Clave

Regla de oro:

Antes de eliminar datos, pregunta: ¿Estos datos son *erróneos* o solo *incómodos para mi modelo*? La diferencia es crucial.



Cómo las decisiones de limpieza introducen sesgos - features

Ejemplo

Escenario: Predecir deserción escolar. Incluimos “código postal” como feature.

Problema:

- Código postal correlaciona con raza y nivel socioeconómico
- Estamos usando un *proxy* de características protegidas
- El modelo puede discriminar “legalmente” por geografía
- Pero realmente discrimina por raza/clase





Otros riesgos





Checklist del Consultor para Detectar Sesgos

Antes de iniciar cualquier proyecto:

1. Sobre la recolección:

- ¿Quién está ausente en estos datos?
- ¿El método de captura favorece a ciertos grupos?
- ¿Tenemos representación balanceada de poblaciones clave?

2. Sobre las variables:

- ¿Qué estamos realmente midiendo?
- ¿Nuestro feature/target es un proxy sesgado?
- ¿Refleja desigualdades históricas?





Checklist del Consultor para Detectar Sesgos

3. Más sobre las variables:


- ¿Alguna variable es proxy de características protegidas?
- ¿Estamos usando datos que perpetúan estereotipos?
- ¿Las correlaciones tienen sentido causal o son espurias?

4. Sobre limpieza:

- ¿A quién afectan desproporcionadamente nuestras decisiones de limpieza?
- ¿Estamos eliminando datos “inconvenientes” vs. erróneos?
- ¿Documentamos el impacto de cada transformación?

5. Sobre el impacto:

- ¿Quién se beneficia de este sistema?
- ¿Quién podría ser perjudicado?
- ¿Cómo auditamos el sistema una vez en producción?





HE2: Consultoría Económica e IAR

Clase 4 - Ciclo de Vida de Datos

Santiago Neira
Catalina Bernal

Enero 29 2026
Semana 2



Universidad de
los Andes

Facultad de
Economía